全国高校 AI 大模型挑战赛 · 参赛技术文档

AI4S 科研助手 Agent

智领科研 · 意图驱动：基于大模型与 Agent 架构的全流程科研助手构建

赛项：大模型驱动，Agent 自主进化

文档版本：V2.0

参赛组别：_____

参赛队伍：_____

日期：2026 年 11 月

目 录

1 项目概述

2 需求分析与赛题覆盖矩阵

3 系统架构设计

4 AI 技术方案

5 核心功能实现

6 测试与部署（含官方数据集实测）

7 技术创新点

8 总结、局限与展望

1 项目概述

2026 年，大语言模型（LLM）与 AI Agent 技术引发了全球科学研究范式的深度变革，AI4S（AI for Science） 已从简单的文献摘要提取，跨越到能够自主进行文献阅读、逻辑推理、假设提出、实验代码生成乃至论文草稿撰写的「AI 科学家助手」新阶段。然而，真实科研场景对学术规范、长上下文、复杂排版与「幻觉零容忍」的确定性要求， 使通用 Chatbot 远无法满足需求。

本项目面向真实科研全流程，从 0 到 1 设计并实现一款全栈式、具备自主规划与协同能力的 **科研助手 Agent。**系统以现代 Web 应用为形态，后端 Agent 通过任务规划、多专家路由与函数调用闭环， 自主调度文档解析、混合检索、学术 API、图谱计算与代码执行等 16 个工具，覆盖赛题要求的六大功能模块， 实现「文献导入 → 解析 → 问答 → 阅读翻译 → 检索追踪推荐 → 图谱综述 → 写作输出」的完整闭环。

> **设计目标：**高可靠（抗幻觉、可溯源、执行护栏）、自主化（Agent 规划与工具闭环）、 全流程（六大模块贯通）、可验证（官方 PDF 数据集实测通过）、可复现（容器化、一键部署）。

1.1 项目速览

维度	数据
功能模块	赛题六大模块全覆盖，9 个功能页面 + 1 个 Agent 统一入口
Agent 内核	Guardrails → Task Planning → Multi-Agent Router → Function Calling 闭环 → Trace 可视化
工具链	16 个注册工具（OpenAI Function Schema），原生调用 + ReAct 双保险
抗幻觉机制	跨语言混合检索（BM25Plus + 向量 + RRF + LLM 重排）+ 内联角标 + 页码锚点 + 角标校验自动修复
官方数据集实测	v1/v7 语义去重命中 98%、改名场景 100% 命中、541 页正版教材 26.3s 入库、15 页扫描件自动识别
质量保障	18 项单元测试、离线自测、AppTest 全页面渲染检查、官方 PDF 验证脚本，全部通过

2 需求分析与赛题覆盖矩阵

2.1 科研痛点

痛点	具体表现	对应能力
信息过载与时效	arXiv 日均更新数百篇，人工检索、过滤、去重、搭建图谱效率低	自动检索、订阅式动态追踪、内容级语义去重
读写效率与严谨	跨语言阅读、细粒度数据提取耗时；模型幻觉在学术场景不可接受	混合 RAG、内联溯源、联动翻译、中译英
复杂版式解析	扫描件、双栏排版、公式、图表、参考文献难以结构化	多模态 OCR、细粒度解析、标题锚点定位
创意落地与复现	数据可视化、架构图、Idea 验证缺乏整合代码与 API 的工具	沙箱代码执行、自动绘图、复现导向推荐

2.2 赛题六大模块覆盖矩阵

赛题模块	要求要点	本系统实现	验证方式
模块一 PDF 管理与细粒度解析	批量上传 + 语义级去重（非仅凭文件名）	正文分段指纹（5 段 × 1200 字）交叉匹配 + 整篇向量双通道，v1/v7 实测 98%、改名实测 100%	verify_official.py 官方 PDF 实测
	扫描件 OCR	文本层自动检测，缺失判定 scanned 并逐页多模态 OCR，带进度条	1706.03762v1_img.pdf 检测通过
	百页长文档工程鲁棒性	541 页正版《Understanding Deep Learning》1523 分块 26.3s 入库，进程内存约 292MB	verify_official.py 实测
模块二 抗幻觉问答	细粒度单篇问答 + 出处锚点	混合检索 + 【n】内联角标 + 论文/页码锚点 + 点击展开原文	问答页检索调试面板
	跨多篇演进对比	BERT vs Transformer、GPT-1/2/3 演化等多文聚合推理	跨文献对比快捷按钮实测
模块三 版式阅读与翻译	标题树导航 + 引用双向跳转	标题锚点定位 References（兼容 IEEE/Nature 排版），[11]→[38] 编号区间实测命中	官方 v1 实测 41 条条目
	中英对比 + 同步滚动	JS 按比例 + 段落对齐双机制同步滚动，悬停联动高亮，划词经后端代理（无密钥暴露）	阅读页实测
模块四 检索追踪推荐	标题下钻下载 + 含金量筛选 + GitHub 复现检测	arXiv/PubMed/Web 三源检索，正则剔除应付式引用，GitHub 链接自动识别加权	检索页实测
	定期追踪 + 点赞/踩 + 多用户推荐	订阅式增量追踪（last-seen 检查点）+ 常驻守护脚本 + 多用户点赞/踩持久化 + 画像加权排序 + 推荐理由	单元测试 + 守护脚本
模块五 引用图谱与综述	20+ 篇图谱 + 基石节点挖掘	标题锚点参考文献区 + 倒排索引候选（IDF 稀有度加权）+ 语义兜底；PageRank/中介/特征向量中心性；n=20 建图 7.9s、n=40 建图 25.0s	bench_graph.py 压测
	自动综述 + Future Work 过滤	图谱驱动综述生成；Future Work 按时间线比对后续摘要，自动标注已解决 idea	图谱页实测
模块六 写作与可视化	无幻觉论文框架	References 仅引用本地真实文献，不足处显式占位	写作页实测
	Mermaid/TikZ 拓扑图 + 沙箱执行	四类脚本生成；run_python 经 AST 白名单护栏校验后隔离执行	单元测试拦截用例
	CSV 可视化 + Figure Caption + 中译英	六类图表（含三维雷达）自动生成，学术图注提炼，中英双向翻译	demo_data/data.csv 实测

2.3 非功能需求

- **鲁棒性：**支持扫描件、双栏、500+ 页长文档与 40 节点图谱；全页面 try/except 错误边界，异常优雅降级不白屏；
- **性能：**长 PDF 解析带进度反馈，大图谱建图带进度条，渲染秒级；内存可控（541 页约 292MB）；
- **可复现：**依赖版本锁定（requirements.txt + Docker），环境变量模板，一键部署；
- **安全性：**API 密钥仅经环境变量注入、绝不进前端页面与仓库；提示注入防护、输出脱敏、代码执行沙箱三层 Guardrails。

3 系统架构设计

3.1 分层架构

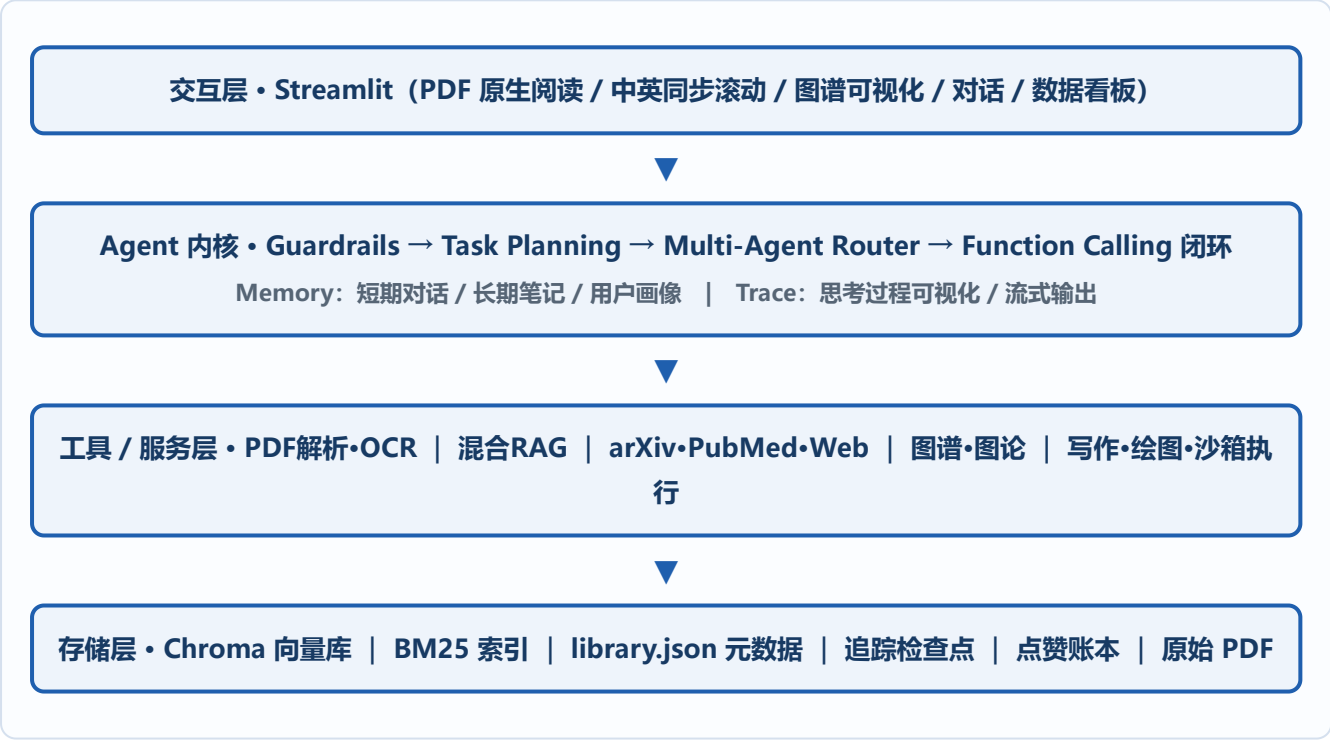




图 3-1 系统主界面（文献库管理页）

3.2 Agent 运行数据流

① 输入	② 防护	③ 规划	④ 路由	⑤ 闭环	⑥ 溯源
自然语言意图	注入/密钥校验	动态拆解步骤	6 类专家分流	函数调用执行	内联引用生成

Agent 内核采用「LLM 优先、规则兜底」策略：路由与规划优先由 LLM 以 JSON 输出，失败时退化为关键词路由与 固定步骤模板；工具执行采用**原生 Function Calling + ReAct 文本解析双保险**，最大迭代 8 轮， 超限则在无新增工具时强制总结，保证闭环可终止。每步记录 Trace（工具名、参数、结果摘要），前端可视化呈现「AI 思考过程」。

3.3 模块解耦

系统按 `core / services / tools / ui / config` 分包：core 仅负责推理与编排（agent / router / planner / memory / guardrails / llm / sandbox），services 封装业务能力（parsing / rag / library / graph / track / translate / writing / state），tools 将 Python 函数统一注册为 OpenAI Function Schema，ui 仅负责渲染。依赖单向向下， 便于测试与扩展；全部离线逻辑可在无 API Key 环境下自测运行。



图 3-2 系统架构设计页（内置架构总览与数据流）

4 AI 技术方案

4.1 模型选型与 Provider 抽象层

系统不绑定单一厂商：所有大模型经 `core/providers.py` 注册表统一接入（全部走 OpenAI 兼容协议， LLMClient 零改动复用），用户在侧边栏下拉即可**热切换**五类 Provider，并声明各自的多模态能力标志：

Provider	base_url	对话模型	视觉模型	多模态
智谱 GLM（默认）	open.bigmodel.cn/api/paas/v4	glm-4-flash	glm-4v	✅
DeepSeek	api.deepseek.com	deepseek-chat	—	❌（OCR 自动降级）
通义千问	dashscope.aliyuncs.com/compatible-mode/v1	qwen-turbo	qwen-vl-plus	✅
OpenAI	api.openai.com/v1	gpt-4o-mini	gpt-4o-mini	✅
本地 Ollama	localhost:11434/v1	qwen2.5:7b	—	❌（完全离线免费）
➕ 自定义端点	任意 OpenAI 兼容 Base URL	任意模型名	任意视觉模型名（留空则降级）	按填写

- **能力路由**：视觉任务（扫描件 OCR、图表理解）按 Provider 的 vl_model 自动路由；无视觉能力的 Provider 优雅降级为明确提示，不抛异常、不中断入库流程；
- **密钥策略**：Key 优先级为「界面手填 > 对应环境变量（ZHIPU_API_KEY / DEEPSEEK_API_KEY / DASHSCOPE_API_KEY / OPENAI_API_KEY）」，Ollama 本地服务免密钥；密钥仅存会话与后端，绝不下发前端；
- **任意模型即填即用**：侧边栏「➕ 自定义端点」直接填写 Base URL + 对话模型 +（可选）视觉模型即可接入任意 OpenAI 兼容端点（vLLM / LM Studio / 硅基流动 / 校内网关……），无需改码或重启；LLM_PROVIDERS_EXTRA 环境变量亦可以 JSON 批量注册；
- Embedding 固定用 Chroma 内置 ONNX 模型（all-MiniLM-L6-v2，384 维）本地推理，与 LLM 选型解耦，保证向量库跨 Provider 可复用。

选型理由：默认智谱 GLM-4-Flash 免费、中文与工具调用稳定，符合赛题「合理规划 API 费用、鼓励开源/本地模型」导向； Provider 层让评审可用任意一家 Key 复现全部功能，也验证了架构的厂商无关性。

4.2 跨语言混合检索（Dense + Sparse + RRF + 重排）

学术场景的典型矛盾是：**文献是英文、提问是中文**，单一向量检索对「超参数、GPU 型号、BLEU 分数」这类 精确词面反而不如关键词检索。系统为此构建了四段式检索管线：

```
查询 → ① 查询扩展（LLM 在线生成英文检索词，离线术语映射表兜底）
     → ② 双路召回：Dense（Chroma 向量 top-k）‖ Sparse（BM25Plus × 多扩展查询取最大）
     → ③ RRF 融合：RRF(d) = Σ 1/(60 + rank_i(d))
     → ④ 可选 LLM 重排 → 注入带【n】编号的编号化上下文
```

分词设计是稀疏路生效的关键：文档与查询统一经「英文 Porter 词干归一 + 中文二元组切分」，并将 BM25 的 IDF 下界设为 0.05（标准 BM25 对「全部文档都含查询词」的小语料库会把 IDF 压成 0，导致中文查询零召回——本系统实测修复后同查询 BM25 召回 7 条 / Dense 召回 11 条，融合后重排精确定位）。扩展词与两路召回数量在问答页「检索调试」面板透明展示，检索行为可审计。

4.3 抗幻觉生成与源头溯源

- 生成仅以编号资料为事实来源，系统提示强制 `【n】` 内联角标、资料不足必须明说、禁止编造；
- 生成后校验角标范围，越界自动触发一次修复重写（validate_citations）；
- 每条资料附论文 ID + 页码锚点，前端点击即展开对应原文片段（Source Tracing）；
- 写作框架的 References 只允许引用本地真实文献，缺失显式占位，杜绝幻觉引用。

4.4 内容级语义去重（不依赖文件名）

去重采用「**整篇向量 + 正文分段指纹**」双通道：入库时均匀抽取 5 个 1200 字内容段生成指纹向量，查重时与库内论文指纹逐段交叉匹配、按来源聚合取平均相似度；同时保留整篇向量相似度作为第二信号，两通道分别给出可解释证据（「分段指纹内容匹配 98%」或「整篇语义相似度 100%」）。判定规则：通用阈值 0.90；同一 arXiv 号且相似度 ≥ 0.7 判为版本演进（仍以语义为依据，非仅凭文件名），并触发「保留最新版」建议与版本差异总结。

> **官方用例实测：**先传 v7 再传 v1 → 命中 98%（最佳段 100%，附 arXiv 同号证据）；把 v1 改名为 `attention_v1.pdf` 再传 → 仍 100% 命中，证明判定完全基于内容。

4.5 多智能体路由与规划

Router 将意图分流至 6 类专家（问答 / 检索 / 图谱 / 写作 / 阅读 / 解析），各专家仅持有完成任务所需的 工具子集，降低误调用面；Planner 将复杂任务动态拆解为有序步骤并交由 Function Calling 闭环执行。

4.6 三层 Guardrails

层	机制	实测
输入层	提示注入特征检测（忽略指令 / 系统提示词提取 / 角色劫持等模式）	拦截用例通过
输出层	响应密钥正则脱敏、引用角标校验与自动修复	单元测试通过
执行层	run_python 先经 AST 静态检查：import 白名单（numpy/pandas/matplotlib/plotly/sklearn 等）、危险名黑名单（os / sys / subprocess / eval / open 等）、dunder 属性链（`__globals__` / `__subclasses__`）与 `__import__` 拦截；违规直接拒绝并返回可读原因	4 类绕过手法全部拦截，正常绘图代码放行

4.7 函数调用与工具链

注册中心将 16 个 Python 工具封装为标准 Function Schema 并按名执行，涵盖：文献检索、多文推理问答、 arXiv / PubMed / 网页搜索、下载入库、引用图谱构建、综述与前沿提炼、写作框架、Mermaid/TikZ 绘图脚本、 数据可视化、翻译、沙箱 Python 执行、记忆读写。所有调用在 Trace 面板可回放。



图 4-1 Agent 统一入口页：自然语言意图 → 工具闭环 → Trace 可视化

5 核心功能实现

5.1 模块一：PDF 管理与细粒度解析

- **语义去重**：见 4.4，附证据链与「覆盖 / 保留 / 取消」三分支交互、v1 vs v7 版本差异自动总结；
- **细粒度解析**：结构化抽取标题、作者机构、摘要、三级标题树、表格、图表、LaTeX 公式、参考文献与附录；扫描件页自动走多模态 OCR 通道；
- **长文档工程**：逐页解析 + 分页分块 + 进度条反馈，541 页正版教材实测 1523 分块 / 26.3s / 292MB。

5.2 模块二：抗幻觉问答与多文推理

单篇问答可定位超参数、GPU 型号数量、BLEU 分数、完整引用等细粒度信息并给原文锚点；多篇推理通过跨文档 Chunk 聚合，支持 BERT 与 Transformer 的承袭 / 抛弃、GPT-1/2/3 参数量演化、LayerNorm 位置与上下文窗口递增等对比分析，答案内联 `【n】`。检索调试面板显示 Dense / Sparse 两路各自召回数与查询扩展词。



图 5-1 跨文献问答与溯源：内联角标 + 页码锚点 + 检索调试

5.3 模块三：版式阅读与双向联动翻译

- 坐标级原生还原单 / 双栏版面（文字可选中），提取标题树导航；
- **引用双向跳转**：以 References / Bibliography 标题锚点定位参考文献区（兼容正文末尾与独立页起始等 IEEE / Springer 排版变体），输入或点击正文 [11] 即返回规范化编号与完整条目原文，官方 v1 实测覆盖 [1]–[38] 区间 41 条；

- 中英对比采用 JS **按比例 + 段落对齐双机制**实现同步滚动与悬停联动高亮，代码与公式保留英文； 划词 / 悬停翻译经**后端代理**调用模型，前端页面不含任何密钥；支持整篇翻译与中译英学术输出。



图 5-2 版式阅读与中英联动翻译

5.4 模块四：检索、动态追踪与个性化推荐

- 给定标题 / 参考文献列表，经 arXiv / PubMed / 搜索引擎自动抓取并入库，支持批量下钻； 引用含金量正则筛选自动剔除应付式引用；GitHub 开源代码链接自动识别并在推荐中加权；
- **订阅式动态追踪：**用户按话题订阅，系统持久化 last-seen 检查点，每次「检查新论文」只返回上次以来 新增条目并推送提示；另提供 `scripts/watch_daemon.py` 常驻守护脚本实现真·定期抓取， 与 Streamlit 会话解耦；
- **多用户个性化推荐：**推荐排序融合「点赞/踩反馈 + 用户画像领域匹配 + 开源代码可得性 + arXiv 分类命中」四因子，逐条生成推荐理由；多用户 ID 隔离反馈账本（JSON 持久化），切换用户可见不同排序。



图 5-3 论文检索、动态追踪与个性化推荐

5.5 模块五：引用图谱与学术综述

引用关系判定三层递进：① 标题锚点定位每篇的参考文献区并切分条目；② 标题 token 倒排索引 + **IDF 稀有度加权**生成候选（词面巧合的泛词如 transformer 得 0 分，稀有词组合才计分），将 $O(n^2)$ 全文比对降为稀疏候选比对；③ 候选内以「条目↔标题」双向包含判定，另以**复用库内向量的语义兜底**捕获缩写标题（如 BERT 论文标题被 Attention 论文引用）。

在「逻辑著作」层建图（同一 arXiv 号取最新版本为唯一节点，旧版本不产生孤立节点），运用 PageRank、入度、中介与特征向量中心性挖掘基石 / 边缘论文；基于图谱自动生成领域综述；提取各文 Future Work，按时间线比对后续论文摘要，自动标注并排除已被解决的旧 idea，提炼真正开放的方向。官方 PDF 实测：BERT → Attention 真实引用边，证据为参考文献条目 100% 匹配，基石论文正确识别为《Attention Is All You Need》。



图 5-4 局域引用图谱：基石节点高亮与交互渲染

5.6 模块六：写作与可视化 Copilot

- 依据 Idea 生成含 Abstract / Introduction / Related Work 的框架，References 仅引用本地真实文献；
- 生成 Mermaid / TikZ / Graphviz / Matplotlib 架构拓扑图脚本，可经沙箱护栏后直接执行出图；
- 读取 CSV 自动生成折线 / 柱状 / 散点 / 三维雷达 / 热力 / 平行坐标图，并提炼符合学术规范、说明核心趋势的 Figure Caption；
- 中文摘要 / 全文一键精准翻译为学术英文。



图 5-5 写作辅助与 CSV 数据可视化 Copilot

6 测试与部署

6.1 官方数据集实测（无 API Key 依赖，可复现）

用例（赛题指定）	输入	实测结果
语义去重 v7→v1	真实官方 PDF	分段指纹内容匹配 **98.0%**（最佳段 100.0%）+ arXiv 同号证据，提示「库中已有版本较更新，建议保留」✅
去重不依赖文件名	v1 改名 attention_v1.pdf	整篇语义相似度 **100%** 命中，文件名为干扰项 ✅
非同篇不误报	BERT 论文入库	相似度 0.652 < 0.90，正确判定为不同论文 ✅
图像扫描件	1706.03762v1_img.pdf	15 页原生文本 0 字符，自动判定 scanned=True，进入 OCR 通道 ✅
超长文档	正版《Understanding Deep Learning》541 页 / 131.4 万字	**1523 分块、入库 26.3s、进程内存约 292MB**，全程进度反馈 ✅
真实引用图谱	v7 + BERT 官方 PDF	1 条真实引用边（BERT→Attention），参考文献条目 100% 匹配证据，基石论文正确 ✅
大图谱性能	20 / 40 篇合成文献	建图 **7.9s / 25.0s**（优化前 49s / 222s），HTML 渲染 0.1–0.2s，边数与精度不变 ✅
跨语言混合检索	中文查询 vs 英文文献	查询扩展生效，BM25 召回 7 条 / Dense 召回 11 条，RRF 融合重排 ✅

6.2 质量保障体系

层级	内容	结果
单元测试	`tests/test_core.py`：分词、跨语言检索、内容去重、引用定位与建图、执行沙箱拦截、Guardrails、追踪增量、点赞推荐、Agent 闭环（Mock LLM），共 18 项	全部通过
离线自测	`scripts/selftest.py`：不依赖网络与 Key 的端到端冒烟（检索链路、去重、图谱、沙箱、追踪）	全部通过
页面渲染	`scripts/apptest_check.py`：Streamlit AppTest 驱动全部页面与核心交互	9/9 页面通过
官方数据验证	`scripts/verify_official.py` / `bench_graph.py`：可一键复跑本文全部实测数字	数据可复现

6.3 错误边界与降级策略

入口统一 try/except 渲染错误卡片（可折叠堆栈）而非白屏；网络失败（arXiv 超时）给出降级提示与重试入口；无 API Key 时功能页显示「请填入 Key」与可演示路径；空文献库时问答 / 图谱 / 阅读 / 写作页给出引导提示。 评审环境多文档并发场景以进度条 + 分页入库控制内存峰值。

6.4 部署方式

```
# 本地（conda）
conda activate ai_research && pip install -r requirements.txt && streamlit run app.py
# Docker（在线演示，端口 8501）
cp .env.example .env    # 填入 API Key（仅环境变量，不入库）
docker compose up -d    # 评审期间保持公网可用，提供评审测试账号
```

依赖版本锁定：requirements.txt 固定 `streamlit>=1.63,<1.64` 等经实测验证的版本区间， 保证评审机与开发机行为一致；前端 HTML 渲染另设兼容层，自动适配新旧组件 API。



图 6-1 技术创新亮点页（与第 7 章呼应）

7 技术创新点

7.1 技术创新

1. **真 Agent 架构而非按钮脚本：**Guardrails → 规划 → 6 专家路由 → Function Calling 闭环 → Trace 全程可视化，LLM 优先 + 规则兜底双保险；

2. **跨语言混合检索：**查询扩展弥合中英词表鸿沟，BM25Plus + 向量双路召回、RRF 融合、LLM 重排，检索过程可审计（调试面板展示两路召回与扩展词）；
3. **内容级去重实证化：**分段指纹交叉匹配 + 整篇向量双通道，各附可解释证据；改名场景 100% 命中，从机制上满足「非仅凭文件名」；
4. **三层引用判定 + IDF 加权候选：**标题锚点参考文献区 → 倒排索引稀有度候选 → 向量复用兜底，兼顾 IEEE/Nature 排版泛化与 40 篇规模 25s 性能；
5. **订阅式增量追踪 + 多用户反馈推荐：**last-seen 检查点只推「上次以来新增」，点赞账本 + 画像 + 开源可得性四因子排序，逐条给推荐理由；
6. **执行级 Guardrails：**AST 白名单沙箱先于执行拦截 4 类绕过手法，密钥永不进前端；
7. **双机制同步滚动阅读：**JS 按比例 + 段落对齐双通道同步、悬停联动高亮、划词后端代理翻译。

7.2 应用创新

1. 贯通科研全流程的单一 Agent 入口，自然语言意图驱动、零脚本操作；
2. 复现导向推荐：优先带 GitHub 开源代码的论文，回应「创意落地与实践复现」痛点；
3. 无幻觉写作：框架 References 只引用本地真实文献，显著提升学术产出可靠性；
4. 离线可复现设计：无 Key 环境下解析 / 检索 / 图谱 / 推荐核心链路全部可演示，规避现场网络风险。

8 总结、局限与展望

本项目围绕真实科研痛点，完成了具备 Agent 内核、跨语言抗幻觉 RAG、内容级语义去重、多模态解析、 真实引用图谱挖掘、订阅式追踪与学术写作可视化能力的全栈科研助手；六大模块闭环贯通，全部关键指标以 **官方赛题 PDF 数据集实测**背书（去重 98%/100%、541 页 26.3s、n=40 建图 25s、真实引用边与基石识别）， 并以三层测试体系保证可复现与稳定。

8.1 当前局限（诚实声明）

- 参考文献区定位依赖标题锚点 + 启发式兜底，对极少数无「References」标题的异形排版仍需人工指定；
- 语义兜底匹配存在缩写标题的边界情形，置信阈值在 precision/recall 间取折中；
- 多用户推荐画像基于领域计数，尚无协同过滤；个性化深度受个人赛数据规模限制；
- OCR 依赖多模态 API，离线场景以原生文本层功能为准。

8.2 后续展望

① 接入更多开源 / 本地推理模型与专用 OCR 管线（PaddleOCR / Marker），进一步降低成本与网络依赖； ② 深化 Multi-Agent 协同与自我进化（基于点赞反馈自动优化工具策略与检索权重）； ③ 扩展真正的多用户协同与云端部署；④ 增强实验代码自动生成与结果复现，向端到端「AI 科学家」演进。

> 附：本文档全部实测数字可由 `python scripts/verify_official.py` 、 `python scripts/bench_graph.py` 、 `python -m unittest discover -s tests` 一键复跑验证。